CURSO DE FORMACIÓN · 20 HORAS

Big Data e IA

Bloque 4: visualización de datos y Business Intelligence



3 horas · Plotly · Google Colab

PLAN DE LA SESIÓN

Tres horas, tres partes

PARTE 1 · ORIENTATIVO 1 H 30

Teoría: estrategia, reporting y casos

- Audiencias, niveles y cómo enseñar los datos
- Tipos de informe y a quién afectan
- Cinco casos de métricas que engañan, en distintos sectores

PARTE 2 · ORIENTATIVO 1 H

Labs: nuestro caso de uso

- KPIs, evolución, xG y mapa de tiros
- Tabla por partido y semáforo
- Los casos con nuestros datos

PARTE 3 · ORIENTATIVO 30 MIN

Cuando el informe avisa

- Verificar, alertar y localizar
- Causas y acciones correctivas
- Databricks, herramientas BI y ejercicio

04

Visualización de datos y Business Intelligence

Bloque 4 · 3 horas

Un cuadro de mando responde preguntas

Datos

Ventas, clientes, operaciones o sensores, ya limpios.

KPIs

Pocas cifras clave que se entienden de un vistazo.

Decisión

Alguien hace algo distinto gracias a lo que ve.

Preguntas de distintos sectores: **banco**, ¿qué clientes pueden abandonar? · **comercio**, ¿qué producto hay que reponer? · **hospital**, ¿cuánto se espera en urgencias? · **logística**, ¿qué rutas se retrasan?

Cuatro preguntas, cuatro niveles

Descriptiva

¿Qué pasó? Un comercio vendió 2 millones de euros el último trimestre.

Diagnóstica

¿Por qué pasó? Un hospital tiene más esperas los lunes por falta de personal.

Predictiva

¿Qué pasará? Un banco estima qué clientes pueden abandonarle.

Prescriptiva

¿Qué hacemos? Una empresa de logística recomienda la ruta que evita el retraso.

4.1 · KPIS

Qué hace buena a una métrica

Medible

Sale de datos que tenemos, calculados siempre igual.

Comparable

Tiene referencia: otro periodo, un objetivo o un rival.

Accionable

Si cambia, sabemos qué mirar o qué decidir.

EJEMPLO

Tiempo de resolución

Soporte técnico: horas entre abrir y cerrar una incidencia.

EJEMPLO

Reclamaciones: 240 frente a 180

Banco: se compara con el mes anterior (cifras ilustrativas).

EJEMPLO

Abandono del carrito

Comercio online: si sube, se revisa el proceso de pago.

4.1 · ESTRATEGIA

Mismo dato, distinto informe

Ejemplo genérico de una empresa.

	QUÉ NECESITA VER	CADA CUÁNTO	DETALLE
Dirección general	Resultado y tendencia frente al objetivo	Mensual	Muy resumido
Responsable de área	Rendimiento frente al plan y a otras áreas	Quincenal	Resumido, con comparativas
Equipo operativo	Qué funciona y qué falla en el día a día	Diaria o semanal	Detallado
Analista de datos	Todo: tablas, filtros y datos limpios	A demanda	Máximo

De lo general al detalle

1. **Titular**
   Una frase con la conclusión: «Las ventas móviles caen mientras las de escritorio suben».

2. **KPIs con referencia**
   Tres a cinco cifras con su objetivo o su semáforo.

3. **Tendencia**
   Cómo ha evolucionado: ¿mejora, empeora o es puntual?

4. **Desglose**
   Dónde ocurre: por región, canal, producto o periodo.

5. **Detalle bajo demanda**
   Tabla y filtros para quien quiera comprobarlo.

1 · Titular

COMERCIO ONLINE

INCORRECTO

«Informe de ventas online · tercer trimestre»

CORRECTO

«Las ventas desde móvil caen un 12 % mientras las de escritorio suben un 3 %»

HOSPITAL

INCORRECTO

«Cuadro de mando de urgencias»

CORRECTO

«La espera en urgencias supera las 3 horas los lunes por la tarde»

QUÉ CAMBIA

El titular es la conclusión en una frase, con una cifra y una comparación.

2 · KPIs con referencia

BANCO

INCORRECTO

«Reclamaciones: 240»

CORRECTO

«Reclamaciones: 240 · mes anterior 180 · +33 % · rojo»

LOGÍSTICA

INCORRECTO

«Entregas a tiempo: 91 %»

CORRECTO

«Entregas a tiempo: 91 % · objetivo 95 % · −4 puntos · ámbar»

QUÉ CAMBIA

Con referencia y semáforo, quien mira sabe si debe preocuparse sin tener que interpretar.

3 · Tendencia

COMERCIO

INCORRECTO

«Ventas medias del año: 50.000 € a la semana»

CORRECTO

«Ventas de las últimas 13 semanas con la línea de objetivo: caen desde la semana 8»

TELECOMUNICACIONES

INCORRECTO

«Tasa de bajas anual: 14 %»

CORRECTO

«Tasa de bajas mensual: sube del 1 % al 2 % en cuatro meses»

QUÉ CAMBIA

Un gráfico de evolución enseña si el problema es puntual, continuado o está empeorando.

4 · Desglose

BANCO

INCORRECTO

«Morosidad total: 4 %»

CORRECTO

«Morosidad: 2 % en hipotecas y 9 % en créditos al consumo»

LOGÍSTICA

INCORRECTO

«Retrasos totales: 8 %»

CORRECTO

«Retrasos: 3 % en ciudad y 15 % en zonas rurales»

QUÉ CAMBIA

El desglose convierte «va mal» en «va mal en este sitio», que es donde se actúa.

5 · Detalle bajo demanda

COMERCIO

INCORRECTO

«Tabla de 5.000 pedidos con 25 columnas en la primera página»

CORRECTO

«Resumen arriba y, al pulsar una región, la lista de sus pedidos»

HOSPITAL

INCORRECTO

«Todos los indicadores del hospital en una sola pantalla»

CORRECTO

«Un indicador por servicio, con acceso al detalle de cada turno»

QUÉ CAMBIA

El detalle debe estar disponible, pero no en primer plano.

4.1 · REPASO DEL BLOQUE 2

Reglas para enseñar datos

Una idea por gráfico

El título dice la conclusión.

Gráfico para la pregunta

Comparar, evolucionar, distribuir o relacionar.

Eje honesto

Las barras empiezan en cero.

Menos tinta y más contexto

Quita lo que no cuenta y compara con una referencia.

Cuatro tipos de reporte

Operativo

Diario o semanal. Qué pasó y si hay algo raro. Lo lee el equipo operativo.

Táctico

Mensual. Tendencias y comparativas. Lo leen los responsables de área.

Estratégico

Trimestral o anual. Objetivos y plan. Lo leen dirección y consejo.

Alerta

Cuando un KPI cruza un umbral. Aviso corto a quien debe actuar.

Lo que nunca debe faltar en un informe

1. **Para quién y qué decisión**
   Una línea al principio que lo diga.

2. **Periodo y fuente**
   De qué fechas y de qué datos sale; cuándo se actualizó.

3. **Definición de cada KPI**
   Cómo se calcula, para que dos personas obtengan la misma cifra.

4. **Limitaciones**
   Muestra pequeña, datos que faltan, cosas que no se pueden concluir.

5. **Siguiente paso**
   Qué se propone hacer, quién y para cuándo.

A quién afecta cada métrica

Quién la lee, qué puede decidir y qué puede salir mal (ejemplos ilustrativos de distintos sectores).

	QUIÉN DECIDE	DECISIÓN POSIBLE	SI SE LEE MAL
Abandono del carrito (comercio)	Responsable de e-commerce	Rediseñar el pago	Se culpa al precio cuando falla la web móvil
Espera en urgencias (hospital)	Dirección asistencial	Reforzar turnos	La media oculta al paciente que espera 8 horas
Morosidad (banco)	Riesgos	Endurecer o relajar la concesión	Se celebra una ratio que baja porque crece la cartera
Entregas a tiempo (logística)	Operaciones	Cambiar rutas o proveedores	Se premia la velocidad y suben los errores

Una cifra sin referencia no dice nada

Elige la referencia

Un objetivo, el histórico propio o el de otra empresa u otro grupo.

Define el umbral

Verde: cumple. Ámbar: vigilar. Rojo: actuar. Se acuerda antes de ver el dato.

Acuerda qué pasa en rojo

Quién recibe el aviso y qué se hace en las 48 horas siguientes.

Ejemplo ilustrativo, entregas a tiempo: **verde** desde el 95 %, **ámbar** entre el 90 % y el 95 %, **rojo** por debajo del 90 %.

Una métrica puede ser correcta y engañar

Banco · morosidad

La ratio baja, pero el denominador también se mueve.

Banco · saldo medio

Un valor extremo mueve la media.

Banco · fraude

Un modelo con 99,5 % de acierto puede no detectar nada.

Ventas · volumen

Más pedidos y menos margen.

Ventas · causa

Dos cosas suben a la vez, pero una no causa la otra.

Cada caso: **titular, números, debate, otro sector y conclusiones**. Todos los escenarios son ilustrativos.

La morosidad baja: ¿buena noticia?

RATIO DE MOROSIDAD DEL BANCO (ILUSTRATIVO)

5 % → 4 %

El banco lo anuncia como un éxito en su informe trimestral.

PREGUNTA PARA LA AUDIENCIA

¿Ha mejorado la salud de la cartera de créditos? Votad: sí, no o depende.

4.2 · CASO 1 · BANCO

Los números detrás de la ratio

	ANTES	DESPUÉS	CAMBIO
Cartera de créditos	100 M€	150 M€	+50 %
Créditos impagados	5 M€	6 M€	+20 %
Ratio de morosidad	5 %	4 %	−1 punto

Ratio de morosidad = créditos impagados ÷ cartera de créditos.

PREGUNTA PARA LA AUDIENCIA

¿Qué ha subido y qué ha bajado? ¿Por qué baja la ratio si hay más dinero impagado?

Qué implicaciones tiene

Escenario ilustrativo: preguntas y consecuencias posibles.

PARA DEBATIR

1. ¿Cuánto dinero se ha dejado de cobrar en términos absolutos?
2. ¿Qué pasará con la ratio si la cartera deja de crecer?
3. ¿Y si los créditos nuevos empiezan a fallar dentro de un año?

QUIÉN SE VE AFECTADO

Dirección

Podría relajar los criterios de riesgo al ver un 4 %.

Riesgos

Si calcula reservas solo con la ratio, podría quedarse corto.

Comunicación

La cifra buena sale fuera; la subida del impago absoluto, no.

El mismo efecto en un hospital

OTRO SECTOR · ILUSTRATIVO

10 % → 8 %
tasa de reingresos

1.000 → 1.500
altas del hospital

100 → 120
reingresos

La tasa baja, pero hay más reingresos que antes: 100 / 1.000 = 10 % y 120 / 1.500 = 8 %.

PREGUNTA PARA LA AUDIENCIA

¿Ha mejorado la atención del hospital o solo ha cambiado el denominador?

El denominador también se mueve

¿Ha mejorado la cartera?
No se puede afirmar: los impagados suben de 5 a 6 M€; solo baja la ratio.

¿Qué sube y qué baja?
La cartera sube un 50 % y los impagados un 20 %: el denominador crece más deprisa.

¿Cuánto se deja de cobrar?
Un millón más. Hay que informar siempre del valor absoluto además de la ratio.

¿Y si la cartera se estanca?
La ratio dejará de caer y subirá cuando los créditos nuevos maduren.

¿Y si los nuevos fallan en un año?
La ratio subirá de golpe y la decisión tomada con el 4 % habrá sido errónea.

¿Y en el hospital?
Misma trampa: la tasa baja y los reingresos suben un 20 %. Comparar por tipo de paciente.

VENTAJA
Una sola cifra fácil de seguir en el tiempo.

DESVENTAJA
Mezcla casos distintos: cambia si cambia la composición.

4.2 · CASO 2 · BANCO

El cliente medio tiene 10.000 €

SALDO MEDIO POR CLIENTE (ILUSTRATIVO)

10.000 €

El banco lo usa para diseñar su próxima campaña de productos.

PREGUNTA PARA LA AUDIENCIA

¿Es un cliente típico alguien con 10.000 € en su cuenta?

Los números detrás de la media

CONCEPTO	VALOR	CÓMO SALE
Clientes con 1.000 €	9	nueve de los diez
Cliente con 91.000 €	1	uno de los diez
Media	10.000 €	100.000 € ÷ 10 clientes
Mediana	1.000 €	el valor central

PREGUNTA PARA LA AUDIENCIA

¿Cuántos clientes tienen un saldo cercano a 10.000 €?

Qué implicaciones tiene

Escenario ilustrativo: preguntas y consecuencias posibles.

PARA DEBATIR

1. ¿Qué producto se diseñaría para un cliente de 10.000 €? ¿A quién llegaría?
2. ¿Qué riesgo supone que un solo cliente tenga el 91 % de los saldos?
3. ¿Qué cifras añadiríais al informe además de la media?

QUIÉN SE VE AFECTADO

Marketing
Podría diseñar para un cliente que no existe.

Dirección
Depende mucho de un único cliente: si se va, el saldo total cae un 91 %.

Analistas
Deben informar de la mediana y de los tramos de clientes.

El mismo efecto en logística

OTRO SECTOR · ILUSTRATIVO

2 días
tiempo medio de entrega

1 día
mediana: lo habitual

11 días
el pedido más lento

Nueve pedidos llegan en 1 día y uno tarda 11: (9 × 1 + 11) / 10 = 2 días de media.

PREGUNTA PARA LA AUDIENCIA

¿Qué cifra describe la experiencia habitual del cliente y cuál señala el problema que hay que resolver?

La media esconde los valores extremos

¿Representa la media al cliente típico?
No: el cliente típico tiene 1.000 €, diez veces menos que la media.

¿Cuántos clientes tienen unos 10.000 €?
Ninguno. La media no coincide con ningún cliente real.

¿Qué producto se diseñaría?
Uno para saldos de 1.000 €; el de 10.000 € llegaría a un solo cliente.

¿Riesgo de un cliente con el 91 %?
Alta dependencia: si se va, los saldos totales caen un 91 %.

¿Qué cifras añadir?
Mediana, percentiles y número de clientes por tramo.

¿Y en logística?
La mediana (1 día) es lo habitual y el máximo (11 días) lo que hay que investigar.

VENTAJA
La media usa todos los datos y permite calcular totales.

DESVENTAJA
Es muy sensible a valores extremos. La mediana los ignora, pero no dice cuánto pesan.

4.2 · CASO 3 · BANCO

Un modelo de fraude que acierta el 99,5 %

ACIERTO DEL MODELO ANTIFRAUDE (ILUSTRATIVO)

99,5 %

El banco presume del modelo en su memoria anual.

PREGUNTA PARA LA AUDIENCIA

¿Os fiaríais de este modelo para proteger a vuestros clientes?

4.2 · CASO 3 · BANCO

Dos modelos para 1.000 operaciones

MODELO	ACIERTO	FRAUDES DETECTADOS	FALSAS ALARMAS
A · «nunca hay fraude»	99,5 %	0 de 5	0
B · modelo que busca fraude	99,1 %	4 de 5	8

PREGUNTA PARA LA AUDIENCIA

¿Cuál preferís? ¿Cómo puede ser mejor el modelo con menos acierto?

Qué implicaciones tiene

Escenario ilustrativo: preguntas y consecuencias posibles.

PARA DEBATIR

1. ¿Qué cuesta más: un fraude sin detectar o bloquear a un cliente honrado?
2. ¿Quién debe decidir cuántas falsas alarmas se aceptan?
3. ¿Qué métricas pediríais además del acierto?

QUIÉN SE VE AFECTADO

Negocio
Fija el coste de cada tipo de error.

Clientes
Cada falsa alarma es un cliente honrado molesto.

Equipo de datos
Debe informar de detección y de falsas alarmas.

4.2 · CASO 3 · OTRO SECTOR

El mismo efecto en una prueba médica

OTRO SECTOR · ILUSTRATIVO

99 %
acierto de decir siempre «sano»

10 de 1.000
personas con la enfermedad

0
casos detectados

Si solo 1 de cada 100 personas tiene la enfermedad, una prueba que siempre dice «sano» acierta el 99 %.

PREGUNTA PARA LA AUDIENCIA

¿Qué tres métricas pediríais a una prueba de cribado además del acierto?

El acierto engaña cuando lo raro es lo importante

¿Os fiaríais del 99,5 %?
No: un modelo que nunca detecta fraude obtiene el mismo acierto.

¿Qué modelo, A o B?
El B: detecta 4 de 5 fraudes y solo pierde 0,4 puntos de acierto.

¿Qué cuesta más?
Lo decide el negocio estimando el coste de cada error y eligiendo el equilibrio.

¿Quién decide las falsas alarmas?
El negocio (riesgo y atención al cliente), con las cifras del equipo de datos.

¿Qué métricas pedir?
Fraudes detectados, falsas alarmas y la matriz de confusión.

¿Y en la prueba médica?
Sensibilidad, falsos positivos y coste de cada error: con casos raros el acierto no sirve.

VENTAJA
El acierto es fácil de explicar a cualquiera.

DESVENTAJA
Con clases desbalanceadas da una imagen falsa del modelo.

4.2 · CASO 4 · VENTAS

Los pedidos suben un 30 %

PEDIDOS DEL TRIMESTRE (ILUSTRATIVO)

+30 %

El equipo comercial lo presenta como su mejor trimestre.

PREGUNTA PARA LA AUDIENCIA

¿Ha ido bien el trimestre?

Los números detrás del volumen

	ANTES	DESPUÉS	CAMBIO
Pedidos	1.000	1.300	+30 %
Margen por pedido	20 €	10 €	−50 %
Margen total	20.000 €	13.000 €	−35 %

Descuento del 10 % sobre un precio de 100 € con coste de 80 €.

PREGUNTA PARA LA AUDIENCIA

¿Qué ha pasado con el dinero que gana la empresa?

Qué implicaciones tiene

Escenario ilustrativo: preguntas y consecuencias posibles.

PARA DEBATIR

1. ¿Qué se premia al comercial: los pedidos o el margen?
2. ¿Qué pasa si el descuento se repite cada trimestre?
3. ¿Cuál sería el KPI correcto para este equipo?

QUIÉN SE VE AFECTADO

Equipo comercial
Si cobra por pedidos, tiene motivos para descontar.

Finanzas
Ve crecer el volumen y caer el beneficio.

Clientes
Pueden acostumbrarse a comprar solo con descuento.

4.2 · CASO 4 · OTRO SECTOR

El mismo efecto en atención al cliente

OTRO SECTOR · ILUSTRATIVO

+40 %
llamadas atendidas por agente

80 % → 60 %
problemas resueltos en la primera llamada

?
¿qué se premia a los agentes?

Para atender más llamadas, los agentes cierran antes, aunque el problema no esté resuelto.

PREGUNTA PARA LA AUDIENCIA

¿Qué indicador usaríais para evaluar y premiar a un agente de atención al cliente?

Actividad no es lo mismo que valor

¿Ha ido bien el trimestre?
No: pedidos +30 % pero margen total −35 %.

¿Qué pasó con el dinero?
Entra menos: 13.000 € frente a 20.000 €.

¿Qué se premia al comercial?
El margen o el beneficio, no los pedidos.

¿Y si el descuento se repite?
Se erosiona el margen y el cliente se acostumbra a comprar con descuento.

¿Cuál es el KPI correcto?
El margen total o por pedido, junto con el volumen.

¿Y en atención al cliente?
Premiar la resolución en la primera llamada, no solo las llamadas atendidas.

VENTAJA
Las métricas de actividad se miden fácil y avisan pronto.

DESVENTAJA
Se pueden inflar sin crear valor.

Las semanas con campaña venden más

VENTAS SEMANALES CON CAMPAÑA FRENTE A SIN CAMPAÑA (ILUSTRATIVO)

+46 %

Ventas medias de 75.000 € con campaña frente a 51.500 € sin campaña.

PREGUNTA PARA LA AUDIENCIA

¿Funciona la campaña? ¿Cuánto presupuesto le daríais?

Los números por temporada

TEMPORADA	SIN CAMPAÑA	CON CAMPAÑA
Temporada alta	80.000 € · 2 semanas	80.000 € · 10 semanas
Temporada normal	50.000 € · 38 semanas	50.000 € · 2 semanas
Total	51.500 €	75.000 €

PREGUNTA PARA LA AUDIENCIA

¿Qué efecto tiene la campaña dentro de cada temporada?

Qué implicaciones tiene

Escenario ilustrativo: preguntas y consecuencias posibles.

PARA DEBATIR

1. ¿Cómo comprobaríais de verdad si la campaña funciona?
2. ¿Qué pasaría si se lanza una campaña en temporada normal esperando un +46 %?
3. ¿Quién decide el presupuesto de campañas con el dato global?

QUIÉN SE VE AFECTADO

Marketing

Podría pedir más presupuesto con un dato engañoso.

Finanzas

Gastaría en campañas que no cambian las ventas.

Analistas

Deben comparar dentro de cada temporada o hacer un experimento.

4.2 · CASO 5 · OTRO SECTOR

El mismo efecto con una app de compras

OTRO SECTOR · ILUSTRATIVO

40 € · 25 €
gasto mensual con app · sin app

+60 %
más gasto en quienes usan la app

?
¿quién se instala la app?

Los clientes que más compraban fueron los primeros en instalarse la app.

PREGUNTA PARA LA AUDIENCIA

¿Subiría un 60 % el gasto si se obliga a todos los clientes a usar la app?

Correlación no es causa

¿Funciona la campaña?
No hay evidencia: dentro de cada temporada las ventas son iguales con y sin campaña.

¿Qué efecto hay por temporada?
Ninguno: 80.000 € y 50.000 € con y sin campaña.

¿Cómo comprobarlo de verdad?
Comparando dentro de cada temporada o con un experimento A/B.

¿Campaña en temporada normal?
No daría un +46 %: ese efecto lo creó la temporada.

¿Quién decide el presupuesto?
Nadie con el dato global: hay que ver el análisis por temporada.

¿Y la app de compras?
Comparar clientes parecidos o probar con un grupo elegido al azar.

VENTAJA
La correlación es rápida de calcular y da pistas.

DESVENTAJA
No prueba causa y puede cambiar al agrupar los datos.

Cinco preguntas antes de fiarse de una métrica

1. **¿Qué hay en el denominador?**
   Si cambia la mezcla, cambia la ratio.

2. **¿Media, mediana o distribución?**
   Mirar si hay valores extremos.

3. **¿Cuántos casos hay y qué tan raro es lo que buscamos?**
   Con clases raras, el acierto engaña.

4. **¿Mide valor o solo actividad?**
   Conectar el KPI con el resultado.

5. **¿Algo influye en las dos variables?**
   Comparar dentro de grupos antes de hablar de causa.

4.3

Nuestro caso de uso: el Sporting 2015/16

Labs · Google Colab y Databricks

Gráficos que se pueden explorar

```python
import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

partidos = pd.read_csv("sporting_partidos.csv", parse_dates=["fecha"])
eventos = pd.read_csv("sporting_eventos.csv")

partidos["puntos_acum"] = partidos["puntos"].cumsum()
tiros = eventos[eventos["type"] == "Shot"].copy()
tiros["gol"] = (tiros["shot_outcome"] == "Goal").astype(int)
```

plotly.express

Gráficos en una línea. Es lo que más usaremos.

graph_objects

Más control, para gráficos combinados.

Primeras cifras de la temporada

39
puntos

40 – 62
goles a favor y en contra

10 · 9 · 19
victorias, empates y derrotas

Son tres números que cualquier directivo entiende. Todo lo demás del cuadro de mando los explica.

4.3 · KPI 1

Evolución de la temporada

python

```python
fig = px.line(partidos, x="jornada", y="puntos_acum", markers=True,
              hover_data=["rival", "resultado"],
              title="Puntos acumulados del Sporting (La Liga 2015/16)")
fig.update_layout(xaxis_title="Jornada", yaxis_title="Puntos")
fig.show()
```

Pregunta

¿En qué tramo de la temporada se estancó el equipo?

hover_data

Al pasar el ratón se ve el rival y el resultado.

4.3 · KPI 2

Local frente a visitante

```python
por_campo = (partidos.groupby("local")[["puntos", "goles_favor", "goles_contra"]].sum()
             .rename(index={True: "Local", False: "Visitante"})
             .reset_index().rename(columns={"local": "campo"}))

fig = px.bar(por_campo.melt(id_vars="campo", var_name="métrica", value_name="valor"),
             x="métrica", y="valor", color="campo", barmode="group", text_auto=True,
             title="Puntos y goles: local frente a visitante")
fig.show()
```

melt

Pasa las columnas a filas para poder agrupar las barras por métrica.

4.3 · KPI 3

¿Creamos más de lo que concedemos?

```python
xg = tiros.groupby(["match_id", "team"])["shot_xg"].sum().reset_index()
xg_favor = xg[xg["team"] == EQUIPO].rename(columns={"shot_xg": "xg_favor"})[["match_id", "xg_favor"]]
xg_contra = xg[xg["team"] ≠ EQUIPO].rename(columns={"shot_xg": "xg_contra"})[["match_id", "xg_contra"]]

fig = px.scatter(xg_partido, x="xg_contra", y="xg_favor", color="resultado",
                 hover_name="rival", title="xG a favor frente a xG en contra")
fig.add_shape(type="line", x0=0, y0=0, x1=limite, y1=limite, line=dict(dash="dash"))
fig.show()
```

Diagonal

Por encima de la línea, el Sporting creó más peligro que el rival.

xG

Calidad de las ocasiones: probabilidad de gol de cada tiro.

4.3 · KPI 4

Goles reales frente a esperados

```python
tiros_sp = tiros[tiros["team"] == EQUIPO]
jugadores = (tiros_sp.groupby("player")
             .agg(tiros=("shot_xg", "size"), goles=("gol", "sum"), xg=("shot_xg", "sum"))
             .sort_values("tiros", ascending=False).head(8).reset_index())

fig = px.bar(jugadores.melt(id_vars=["player", "tiros"], value_vars=["goles", "xg"],
                            var_name="medida", value_name="valor"),
             x="player", y="valor", color="medida", barmode="group")
fig.show()
```

Lectura

Quien marca más que su xG aprovecha bien sus ocasiones, o ha tenido suerte.

Cada punto, un tiro

python

```
fig = px.scatter(tiros_sp, x="x", y="y", color="resultado_tiro", size="shot_xg",
                 hover_data=["player", "minute", "shot_body_part"],
                 title="Tiros del Sporting (tamaño = xG)")
# Líneas del campo (120 x 80); el eje y se invierte para coincidir con los datos
fig.add_shape(type="rect", x0=0, y0=0, x1=120, y1=80, line=dict(color="gray"))
fig.update_yaxes(range=[82, -2], scaleanchor="x")
fig.show()
```

Posición

x e y siguen las coordenadas de StatsBomb: el campo mide 120 por 80.

Tamaño

Cuanto mayor el punto, más peligrosa la ocasión.

Una fila por partido, un KPI por columna

python

```
xg = tiros.groupby(["match_id", "es_sporting"])["shot_xg"].sum().unstack(fill_value=0)
xg.columns = ["xg_contra", "xg_favor"]

pases = (eventos[eventos["type"] == "Pass"]
         .groupby(["match_id", "es_sporting"])["pase_completo"].mean().unstack())
pases.columns = ["pase_rival", "pase_sporting"]

m = (partidos.set_index("match_id").join(xg).join(pases)
     .reset_index().sort_values("jornada"))
m["dif_xg"] = m["xg_favor"] - m["xg_contra"]
```

Por qué

Todos los gráficos y alertas siguientes salen de esta tabla.

unstack

Pasa True y False de es_sporting a dos columnas.

De la cifra al estado

Resultado: los tres en rojo (1,03 puntos, −0,46 de xG; 69,6 % de pases frente al 77,4 % de los rivales).

python

```
kpis = pd.DataFrame({
    "KPI": ["Puntos por partido", "Diferencia de xG", "Pases completos (%)"],
    "valor": [m.puntos.mean(), m.dif_xg.mean(), m.pase_sporting.mean() * 100],
    "objetivo": [1.4, 0.0, m.pase_rival.mean() * 100], # el 1,4 es un objetivo de ejemplo
    "margen": [0.3, 0.3, 3]})
def estado(valor, objetivo, margen):
    if valor ⩾ objetivo: return "verde"
    if valor ⩾ objetivo - margen: return "ámbar"
    return "rojo"

kpis["estado"] = [estado(*f) for f in kpis[["valor", "objetivo", "margen"]].itertuples(index=False)]
```

Varios gráficos en una sola vista

python

```
fig = make_subplots(rows=1, cols=2,
                    subplot_titles=("Puntos acumulados", "Goles por jornada"))

fig.add_trace(go.Scatter(x=partidos["jornada"], y=partidos["puntos_acum"],
                         mode="lines+markers", name="Puntos"), row=1, col=1)
fig.add_trace(go.Bar(x=partidos["jornada"], y=partidos["goles_favor"], name="A favor"), row=1, col=2)
fig.add_trace(go.Bar(x=partidos["jornada"], y=-partidos["goles_contra"], name="En contra"), row=1, col=2)

fig.update_layout(title_text="Dashboard — Sporting, La Liga 2015/16", barmode="relative")
fig.show()
```

Composición

make_subplots coloca varios gráficos en la misma figura.

Los cinco puntos con nuestros datos

Lo que se construirá en las próximas slides y en el notebook.

	EJEMPLO CORRECTO CON LOS DATOS DEL SPORTING
Titular	«Fuera de casa el Sporting crea menos de la mitad de peligro: 0,66 de xG frente a 1,50 por partido»
KPIs con referencia	«Pases completos: 69,6 % · rivales 77,4 % · –7,8 puntos · rojo»
Tendencia	«Puntos de los últimos 5 partidos: la alerta salta en las jornadas 19, 20, 28 y 29»
Desglose	«Diferencia de xG: +0,22 en casa y –1,13 fuera; los cinco peores partidos, todos fuera»
Detalle bajo demanda	«Tabla ordenable al final y gráfico con rival y resultado al pasar el ratón»

Pases: ¿mismo efecto que en el banco?

NUESTRO DATO · SPORTING 2015/16

70,7 %
pases completos del Sporting

78,3 %
pases completos de los rivales

24,7 %
pases de más de 30 m del Sporting (rivales: 20,1 %)

El Sporting da más pases largos, que se completan menos. La ratio general mezcla distancias distintas.

PREGUNTA PARA LA AUDIENCIA

Si los rivales pasaran con el mismo reparto de distancias que el Sporting, ¿completarían menos? ¿Cuánto menos?

CONCLUSIÓN

Completarían menos, pero solo 1,1 puntos menos (77,2 % frente a 78,3 %). El reparto de distancias explica una parte pequeña: el resto de la diferencia es real.

xG: ¿la media representa a un partido normal?

NUESTRO DATO · SPORTING 2015/16

1,08 · 0,88
xG a favor por partido: media · mediana

4,68
xG de la jornada 21 (Real Sociedad en casa, 5-0)

0,98
media sin ese partido

Un partido excepcional sube la media de la temporada.

PREGUNTA PARA LA AUDIENCIA

¿Qué cifra usaríais para describir cuánto peligro crea un Sporting normal?

CONCLUSIÓN

La mediana (0,88): sin la jornada 21 la media baja de 1,08 a 0,98. Para un partido normal conviene la mediana y enseñar la distribución.

Goles: acertar casi siempre no demuestra nada

NUESTRO DATO · SPORTING 2015/16

100
goles

926
tiros de los dos equipos

89,2 %
acierto de «nunca habrá gol»

Solo el 10,8 % de los tiros acaban en gol: acertar «casi siempre» es muy fácil.

PREGUNTA PARA LA AUDIENCIA

Si construimos un modelo que prediga goles, ¿cómo lo evaluaríamos?

CONCLUSIÓN

Por la fracción de goles que detecta y por las falsas alarmas, no por el acierto: «nunca habrá gol» ya acierta el 89,2 %.

Pases, tiros y xG: actividad frente a valor

NUESTRO DATO · SPORTING 2015/16

0,07
correlación entre pases y puntos por partido

0,20
correlación entre tiros y puntos

0,47
correlación entre xG y puntos

Actividad (pases, tiros) frente a calidad de las ocasiones (xG). Solo 38 partidos: son pistas, no pruebas.

PREGUNTA PARA LA AUDIENCIA

¿Qué métrica del Sporting se parece a los «pedidos» y cuál al «margen»?

CONCLUSIÓN

Los pases son los «pedidos»: se miden fácil y casi no se relacionan con los puntos. El xG hace de «margen»: mide la calidad de las ocasiones y se relaciona bastante más.

Tiros y puntos: ¿qué más influye?

NUESTRO DATO · SPORTING 2015/16

0,03 · 0,25
correlación tiros-puntos en casa · fuera (total: 0,20)

12,3 · 7,7
tiros por partido en casa · fuera

1,32 · 0,74
puntos por partido en casa · fuera

Jugar en casa sube a la vez los tiros y los puntos. Con 19 partidos por grupo las correlaciones son poco estables.

PREGUNTA PARA LA AUDIENCIA

¿Qué factor mueve a la vez los tiros y los puntos del Sporting?

CONCLUSIÓN

El campo: jugar en casa sube tiros y puntos a la vez. Al separar por campo la relación cambia, así que hay que comparar dentro de cada grupo.

Un KPI en rojo: qué hacemos

1. **Comprueba que el dato es fiable**
   Un fallo de carga puede parecer un problema deportivo.
2. **Dimensiona**
   ¿Cuánto se desvía y desde cuándo? ¿Es puntual o continuado?
3. **Localiza**
   Desglosa por local y visitante, rival, periodo o jugador.
4. **Busca la causa**
   Dato, azar, contexto o proceso: se descartan por ese orden.
5. **Actúa y mide**
   Una acción, un responsable, un plazo y el KPI que dirá si funcionó.

4.4 · PASO 1

Comprobar el dato antes de dar la alarma

python

```python
checks = {
    "38 partidos": len(partidos) == 38,
    "sin partidos repetidos": partidos["match_id"].is_unique,
    "sin nulos en puntos": partidos["puntos"].notna().all(),
    "sin eventos duplicados": not eventos.duplicated(["match_id", "event_id"]).any(),
    "todos los partidos tienen eventos": set(partidos["match_id"]) == set(eventos["match_id"]),
}
for nombre, ok in checks.items():
    print("OK " if ok else "FALLA", nombre)
```

Automatizable

Se ejecuta antes de cada informe y avisa si algo falla.

Resultado

Con los datos del curso las cinco comprobaciones pasan.

4.4 · PASOS 2 Y 3

Detectar una racha con una alerta

python

```
m["puntos_5"] = m["puntos"].rolling(5).sum() # puntos de los últimos 5 partidos
m["alerta"] = m["puntos_5"] ⩽ 2

fig = px.line(m, x="jornada", y="puntos_5", markers=True,
              title="Puntos en los últimos 5 partidos")
fig.add_hline(y=2, line_dash="dash", annotation_text="Umbral de alerta")
rojo = m[m["alerta"]]
fig.add_scatter(x=rojo["jornada"], y=rojo["puntos_5"], mode="markers",
                marker=dict(size=14, color="#D1495B"), name="Alerta")
fig.show()
```

Qué detecta

Las jornadas 19, 20, 28 y 29 cruzan el umbral.

Umbral

El 2 es un criterio de ejemplo; se acuerda antes.

4.4 · PASO 3

Localizar dónde está el problema

python

```python
# ¿Se concentra en algún tipo de partido?
print(m.groupby("local")[["puntos", "xg_favor", "xg_contra", "dif_xg"]].mean().round(2))

# ¿Qué partidos tiran de la media hacia abajo?
cols = ["jornada", "rival", "local", "resultado", "xg_favor", "xg_contra"]
print(m.sort_values("dif_xg").head(5)[cols].round(2))
```

En casa

1,32 puntos por partido y +0,22 de diferencia de xG.

Fuera

0,74 puntos y −1,13 de diferencia de xG.

Los 5 peores

Todos fuera. El peor: Barcelona, con 4,72 de xG en contra.

4.4 · PASO 4

Cuatro explicaciones posibles

Fallo de datos

El informe se equivoca: carga incompleta o definición distinta.

Azar y muestra pequeña

Con pocos partidos o pocos goles el resultado oscila aunque el juego no cambie.

Contexto

Rival fuerte, lesiones, calendario o jugar fuera de casa.

Proceso

Algo del juego o de la organización falla de verdad.

Con datos del curso: en **4 derrotas (jornadas 6, 12, 26 y 29)** el Sporting creó más xG que el rival.

4.4 · PASO 5

De la alerta a la acción correctiva

Las causas y las acciones son hipótesis de ejemplo para discutir.

	CAUSA A CONTRASTAR	ACCIÓN	CÓMO MEDIR
Pases bajos: 69,6 % frente a 77,4 %	Salida de balón arriesgada	Trabajar la circulación	% de pases en 5 partidos
xG en contra alto fuera de casa	Línea defensiva demasiado adelantada	Ajustar la altura de la defensa	xG en contra de los próximos partidos fuera
Racha con 2 puntos o menos en 5 partidos	Calendario y juego a la vez	Revisión del plan con el cuerpo técnico	Puntos y xG de los 5 siguientes
Una cifra que no cuadra	Fallo de carga	Corregir el proceso y reenviar el informe	Pasan los controles de calidad

4.4 · CUIDADO AL CORREGIR

Cuatro trampas

La métrica se vuelve objetivo

Si solo se premia el % de pases completos, se jugará seguro y sin riesgo.

Corregir demasiado pronto

Reaccionar a dos partidos es reaccionar al ruido. Hay que esperar muestra.

Demasiados KPIs

Con veinte indicadores siempre habrá alguno en rojo y ninguno importa.

Buscar culpables

El informe señala procesos, no personas: si no, se esconderán los datos.

4.4 · CONFIANZA

Que el informe sea fiable en el tiempo

Definición única

Cada KPI se calcula igual para todos y está documentado.

Responsable y calendario

Quién lo prepara, quién lo revisa y cuándo se actualiza.

Registro de decisiones

Qué se decidió a partir de cada informe y qué efecto tuvo.

El mismo KPI con SQL

Databricks · SQL

```
%sql
SELECT p.jornada, p.rival, p.local, p.puntos,
  ROUND(SUM(CASE WHEN e.team = 'Sporting Gijón' THEN e.shot_xg ELSE 0 END), 2) AS xg_favor,
  ROUND(SUM(CASE WHEN e.team <> 'Sporting Gijón' THEN e.shot_xg ELSE 0 END), 2) AS xg_contra
FROM eventos e JOIN partidos p ON p.match_id = e.match_id
WHERE e.type = 'Shot'
GROUP BY p.jornada, p.rival, p.local, p.puntos
ORDER BY p.jornada
```

Requisito

Las vistas eventos y partidos del Bloque 3.

Gráfico

En la tabla de resultados, añadir una visualización.

Qué existe y cómo se trabaja

Solo explicación: en el curso trabajamos con Colab y Databricks.

	IDEA CENTRAL	CÓMO SE TRABAJA
Power BI	Informes y paneles de Microsoft	Power Query para preparar datos; medidas en lenguaje DAX
Tableau	Exploración visual interactiva	Arrastrar campos; hojas, cuadros de mando e historias
Qlik	Modelo asociativo	Al seleccionar un dato se resaltan los relacionados
Looker Studio	Informes web de Google	Conecta con Hojas de cálculo y BigQuery; se comparte por enlace
Metabase y Superset	Código abierto basado en SQL	Se instalan en servidor propio; consultas en SQL o con asistente

El flujo típico en una herramienta de BI

1. **Conectar**
   A ficheros, bases de datos o servicios en la nube.

2. **Preparar y modelar**
   Limpiar, unir tablas y definir relaciones: lo que hicimos con pandas y Spark.

3. **Definir medidas**
   Los KPIs como cálculos reutilizables, que se definen una vez.

4. **Diseñar visuales y filtros**
   Arrastrando campos, con interacción entre gráficos.

5. **Publicar y mantener**
   Permisos por rol, actualización programada y avisos.

Lo que hemos hecho, en lenguaje de BI

	EN UNA HERRAMIENTA DE BI	QUÉ CAMBIA
pd.read_csv, spark.read	Conexión a la fuente	Se configura una vez y se refresca sola
merge, groupby, SQL	Modelo de datos	Relaciones entre tablas con menos código
Columna dif_xg	Medida	Se reutiliza en cualquier gráfico y filtro
px.line, px.bar	Visual	Se construye arrastrando campos
make_subplots	Cuadro de mando	Con filtros que afectan a todos los gráficos
Compartir el notebook	Publicar el informe	Permisos por rol y actualización programada

Del gráfico al mensaje

1. **Empieza por la audiencia**
   ¿Quién lo mira y qué decisión tomará?

2. **Un mensaje por gráfico**
   El título dice la conclusión, no el nombre de la variable.

3. **Da contexto**
   Compara con un objetivo, con el periodo anterior o con un rival.

4. **Cierra con una acción**
   Qué haríamos distinto a partir de lo que vemos.

EJERCICIO · 30 MINUTOS

Ahora te toca a ti

1. Añade un KPI nuevo: porcentaje de pases completos del Sporting en cada partido y su relación con el resultado.
2. ¿En qué partidos perdió el Sporting pese a crear más peligro (xG a favor > xG en contra)? ¿Mala suerte u otra causa?
3. Define un semáforo para un KPI nuevo: elige la referencia y el umbral, y justifica por qué.
4. Elige una alerta del informe y escribe su ficha de acción: causa a contrastar, acción, responsable y KPI para medir si funciona.

CIERRE

Lo que nos llevamos

- Un informe se diseña para alguien y para una decisión concreta.
- Una métrica correcta puede engañar: denominador, extremos, clases raras, actividad y causas ocultas.
- Ante un KPI en rojo: verificar, dimensionar, localizar, buscar la causa y actuar.
- Toda acción correctiva lleva un responsable y un KPI que mida si funcionó.

SIGUIENTE BLOQUE

IA y Machine Learning

Qué es aprender de los datos y cómo se evalúa un modelo.