CURSO DE FORMACIÓN · 20 HORAS

Big Data e IA

Bloque 5: fundamentos de Inteligencia Artificial



3 horas · Conceptos · Ética

PLAN DE LA SESIÓN

Tres horas, tres partes

PARTE 1 · ORIENTATIVO 1 H

Conceptos

- IA, Machine Learning y Deep Learning
- Tipos de aprendizaje
- Ciclo de un proyecto de ML

PARTE 2 · ORIENTATIVO 1 H

Datos y modelos

- Variables y etiqueta
- Entrenamiento y test
- Sobreajuste y métricas

PARTE 3 · ORIENTATIVO 1 H

Algoritmos y ética

- Algoritmos que usaremos
- Sesgos y límites
- Actividad en grupo

05

Fundamentos de Inteligencia Artificial

Bloque 5 · 3 horas

5.1 · CONCEPTOS

IA, Machine Learning y Deep Learning

Inteligencia Artificial

Máquinas que realizan tareas que requieren inteligencia.

Machine Learning

La máquina aprende patrones a partir de datos en lugar de seguir reglas escritas a mano.

Deep Learning

Machine Learning con redes neuronales de muchas capas; destaca con imágenes, texto o audio.

Anidados: **IA ⊃ Machine Learning ⊃ Deep Learning**.

Reglas a mano frente a aprender de los datos

	PROGRAMACIÓN CLÁSICA	MACHINE LEARNING
Entra	Datos y reglas escritas	Datos y respuestas conocidas
Sale	Respuestas	Reglas: el modelo
Ejemplo	Si el tiro está a menos de 6 m, es peligroso	El modelo descubre qué tiros acaban en gol
Cuándo	Las reglas son claras y pocas	Hay muchos factores y datos de ejemplo

Con etiqueta, sin etiqueta o por premio

Supervisado

Hay una respuesta conocida (¿acabó en gol?). El modelo aprende a predecirla.

No supervisado

No hay respuesta: el modelo busca grupos, como las zonas de remate.

Por refuerzo

Un agente prueba acciones y recibe premios o castigos. Solo lo mencionamos.

5.1 · QUÉ PREDECIMOS

Clasificación y regresión

Clasificación

La respuesta es una categoría: gol o no gol; victoria, empate o derrota.

Regresión

La respuesta es un número: cuántos puntos sumará un equipo; cuántos goles se esperan.

5.1 · CICLO DE UN PROYECTO

De la pregunta al modelo en uso

1 **Definir el problema**
¿Qué decisión se quiere mejorar y cómo se medirá el éxito?

2 **Preparar los datos**
Limpiar, unir y crear variables útiles.

3 **Entrenar y evaluar**
Ajustar el modelo y medirlo con datos que no ha visto.

4 **Usarlo y vigilarlo**
Ponerlo en marcha y comprobar que sigue funcionando.

Variables y etiqueta

Datos de ejemplo: cada fila es un tiro, las dos primeras columnas son las variables y la última, la etiqueta.

	DISTANCIA (M)	PRESIÓN	¿GOL?
Tiro A	8	sí	no
Tiro B	5	no	sí
Tiro C	22	no	no

Nunca se evalúa con lo que se estudió

75 %
para entrenar: el modelo aprende de estos casos

25 %
para test: casos que el modelo no ha visto

Como un examen: no se pone en el examen el mismo ejercicio que se resolvió en clase.

Memorizar no es aprender

Sobreajuste

El modelo se aprende los casos de entrenamiento, incluso el ruido. En test falla.

Infraajuste

El modelo es demasiado simple y no capta el patrón ni en entrenamiento.

Lo que buscamos

Un modelo que generalice: que rinda parecido con casos nuevos.

Cuatro métricas de clasificación

Accuracy

Porcentaje de aciertos totales. Engaña con clases desiguales.

Precisión

De lo que dijo «gol», cuánto lo fue.

Recall

De los goles reales, cuántos detectó.

AUC

Si ordena bien: un gol suele recibir más probabilidad que un no gol. 0,5 es azar y 1 es perfecto.

El accuracy engaña

1 de 10

tiros acaba en gol, aproximadamente

≈ 90 %

de acierto diciendo siempre «no gol»

Un modelo inútil puede parecer excelente si solo miras el accuracy.

5.3 · ALGORITMOS

Los que veremos en el bloque 6

Regresión logística

Sencillo y fácil de explicar. Calcula una probabilidad.

Random Forest

Muchos árboles de decisión que votan. Robusto con datos en tabla.

KMeans

No supervisado: agrupa casos parecidos, como zonas de remate.

Red neuronal

Solo una prueba pequeña, para comparar con los demás.

Antes de confiar en un modelo

Datos pequeños

Una temporada y unos cien goles: no sirve para juzgar a un jugador.

Sesgo de la muestra

Solo hay tiros de partidos del Sporting; los rivales aparecen contra él.

Personas

Aunque los datos sean públicos, decidir contratos o salarios exige cuidado y respetar la normativa.

Errores y su coste

¿Qué cuesta más: descartar a un buen jugador o fichar a uno que no lo es?

ACTIVIDAD · 20 MINUTOS

Clasifica el problema

En parejas: ¿supervisado o no?, ¿clasificación o regresión?, ¿qué datos usarías?

1. Predecir si un cliente se dará de baja el mes que viene.
2. Agrupar a los clientes en perfiles sin saber de antemano cuántos hay.
3. Estimar cuántos puntos sumará el Sporting una temporada.
4. Detectar si un correo es spam.

CIERRE

Lo que nos llevamos

- Machine Learning es aprender patrones de los datos, no escribir reglas a mano.
- Se evalúa con datos que el modelo no ha visto.
- Con clases desiguales, el accuracy engaña.
- Un modelo bueno técnicamente puede ser injusto o poco fiable.

SIGUIENTE BLOQUE

Machine Learning aplicado

Un modelo de xG con datos del Sporting.