CURSO DE FORMACIÓN · 20 HORAS

Big Data e IA

Bloque 7: proyecto integrador final



3 horas · Trabajo individual o en grupo · Presentación

PLAN DE LA SESIÓN

Tres horas, tres partes

PARTE 1 · ORIENTATIVO 20 MIN

Arranque

- La pregunta de negocio
- El flujo completo
- Cómo se entrega y se presenta

PARTE 2 · ORIENTATIVO 1 H 40 MIN

Trabajo

- Pasos 1 a 5 del notebook
- Conclusiones en la plantilla
- Preparar la presentación

PARTE 3 · ORIENTATIVO 1 H

Presentaciones y cierre

- Presentación de cada grupo
- Preguntas
- Cierre del curso

07

Proyecto integrador final

Bloque 7 · 3 horas

7.1 · LA PREGUNTA DE NEGOCIO

Qué queremos responder

Pregunta 1

¿Qué explica los puntos que sumó el Sporting?

Pregunta 2

¿Qué jugadores rematan mejor o peor de lo esperado?

7.1 · EL FLUJO COMPLETO

De los datos a la recomendación

1 **Datos crudos y limpieza**
Cargar los CSV limpios del bloque 2.

2 **Agregación**
Una fila por partido, como en Spark y pandas (bloque 3).

3 **Análisis**
Qué variables se relacionan con los puntos (bloques 2 y 4).

4 **Modelo de IA**
xG por tiro con Random Forest (bloques 5 y 6).

5 **Visualización y conclusiones**
Gráficos claros y recomendación (bloque 4).

Paso 2: una fila por partido

python

```
tiros = eventos[eventos["type"] == "Shot"].copy()
tiros["gol"] = (tiros["shot_outcome"] == "Goal").astype(int)
pases = eventos[eventos["type"] == "Pass"].copy()
pases["completo"] = (pases["pass_outcome"] == "Completo").astype(int)

# xg_favor, xg_contra, tiros_favor, pases_ok_% ... por partido
# se unen a la tabla de partidos con merge
```

Resultado

Una tabla con una fila por partido y las variables de juego.

Paso 3: ¿qué se relaciona con los puntos?

python

```python
cols = ["puntos", "goles_favor", "goles_contra", "xg_favor", "xg_contra",
        "dif_xg", "tiros_favor", "pases_ok_%"]

print(tabla[cols].corr()["puntos"].drop("puntos").round(2).sort_values(ascending=False))

sns.regplot(data=tabla, x="dif_xg", y="puntos")
```

Cuidado

Con 38 partidos las correlaciones son orientativas, no concluyentes. Correlación no es causalidad.

Paso 4: cuánto se esperaba de cada tirador

python

```python
# Variables: distancia, ángulo, presión, de primeras...
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
tiros["xg_modelo"] = cross_val_predict(rf, X, y, cv=cv, method="predict_proba")[:, 1]

# Ahora cada tiro tiene una probabilidad predicha por un modelo que NO lo vio
```

cross_val_predict

Cada tiro se predice con un modelo que no lo ha visto al entrenar.

Para qué

Comparar goles reales con goles esperados por jugador.

Paso 5: enseñar los resultados

Rematadores

Goles reales frente a goles esperados por jugador, con un mínimo de 15 tiros.

Evolución

Puntos acumulados y diferencia de xG por jornada.

Regla

Un mensaje por gráfico y el título dice la conclusión.

7.2 · PASO 6

Conclusiones: la plantilla

1 · La variable

¿Qué variable se relaciona más con los puntos?

2 · Los tiradores

¿Quién remata por encima o por debajo de lo esperado? ¿Es fiable con tan pocos tiros?

3 · La recomendación

¿Qué aconsejarías a un cuerpo técnico?

4 · Limitaciones

Una temporada, pocos goles, sin posición de defensores, calidad del dato.

5 · A producción

Spark en un clúster, todas las competiciones, un cuadro de mando en Power BI o Tableau.

7.3 · PRESENTACIÓN

10 a 15 minutos por grupo

Citar siempre a StatsBomb Open Data como fuente.

1. **Pregunta de negocio**
   1 minuto.
2. **Qué se hizo en cada etapa**
   Datos, limpieza, agregación, modelo y visualización: 5 minutos.
3. **Resultados y hallazgos**
   5 minutos.
4. **Recomendación y limitaciones**
   3 minutos, más preguntas.

7.3 · EVALUACIÓN

Qué miramos

Pregunta clara

Está bien definida y se puede responder con los datos.

Rigor

Datos limpios, método correcto y no mezclar entrenamiento con test.

Mensaje

Gráficos legibles y conclusiones que se sostienen.

Honestidad

Limitaciones señaladas y fuente citada.

CIERRE DEL CURSO

Lo que recorrimos en 20 horas

7
bloques, de los fundamentos al proyecto

1
dataset real, de principio a fin

0
instalaciones: todo con herramientas gratuitas

De los datos crudos a una recomendación: **ingesta, procesamiento, visualización y modelo**.

Y AHORA QUÉ

Para seguir aprendiendo

Más datos

El repositorio de StatsBomb tiene más competiciones y temporadas.

Más herramientas

Probar Power BI o Tableau con estos mismos datos.

Más IA

Probar otros modelos y medir su calidad con rigor.